

Projet - Traitement numérique des données

Projet 3 - Dimitri LE GALLIC, Noémie GOBALSAMY
Haberman's Survival Data

Contents

1	Introduction	1
2	Objet de l'analyse	1
3	Ensemble de données	1
3.1	Présentation	1
3.2	Vérification	2
4	Analyse des données	3
4.1	Statistiques univariées	3
4.2	Statistiques bivariées	4
4.3	Statistiques multivariées	5
4.3.1	ACP	5
4.3.2	K-means	8
5	Commentaires	9

1 Introduction

Ce rapport a pour objectif l'étude d'un ensemble de données réelles, par des méthodes dites classiques d'analyse de données. Nous utiliserons à cet effet le langage de programmation R ainsi que certaines de ses bibliothèques élémentaires. Un accent tout particulier est mis sur la réflexion et le processus de cette étude, au delà des simples résultats numériques.

2 Objet de l'analyse

L'objet de notre analyse est un jeu de données appelé "Haberman's Survival Data". Il est le résultat d'une étude menée entre 1958 et 1970 à l'hôpital de l'université de Chicago sur la survie des patients ayant été opérés pour des cancers du sein.

3 Ensemble de données

3.1 Présentation

Il nous est fourni un fichier *haberman.names* afin de nous éclairer sur la nature des variables étudiées. Nous disposons des informations de suivi de **306 patients**. Ces dernières s'organisent autour de 4 attributs :

- l'âge du patient lors de l'opération; *numérique*
- l'année de l'opération, (sous forme année-1900); *numérique*
- Nombre de noeuds lymphatiques positifs détectés; *numérique*
- Survie du patient : **1** en cas de survie, **2** sinon

Selon ce fichier, aucune valeur d'attribut ne manque.

3.2 Vérification

Une première étape dans l'analyse des données est de vérifier la justesse des informations qui nous sont présentées :

```
1 > haberman <- read.csv("~/Binome3/haberman.data", header=FALSE)
2 > nrow(haberman)
3 [1] 306
4 > ncol(haberman)
5 [1] 4
```

Il y a bien **306** instances ayant chacune **4** attributs. On peut désormais vérifier la cohérence de ces attributs :

```
1 library(validate)
2
3 #chargement du dataset
4 haberman <- read.csv("~/haberman.data", header=FALSE)
5 colnames(haberman) <- c("age", "year", "nodes", "status")
6
7 #affichage des types des variables et verification qu'il n'y a pas de variable null
8 str(haberman)
9 any(is.na(haberman))
10
11 #verification de la validite des donnees
12 rules <- validator((age > 0 & age<100)
13                   , year >= 58 & year <= 70
14                   , nodes >= 0
15                   , status==1 | status==2)
16 out <- confront(haberman, rules)
17 summary(out)
```

```
1 > str(haberman)
2 'data.frame': 306 obs. of 4 variables:
3 $ age : int 30 30 30 31 31 33 33 34 34 34 ...
4 $ year : int 64 62 65 59 65 58 60 59 66 58 ...
5 $ nodes : int 1 3 0 2 4 10 0 0 9 30 ...
6 $ status: int 1 1 1 1 1 1 1 2 2 1 ...
7
8 > any(is.na(haberman))
9 [1] FALSE
10
11 > summary(out)
12 name items passes fails nNA error warning
13 1 V1 306 306 0 0 FALSE FALSE
14 2 V2 306 306 0 0 FALSE FALSE
15 3 V3 306 306 0 0 FALSE FALSE
16 4 V4 306 306 0 0 FALSE FALSE
```

Le jeu de données est donc bien celui attendu. On peut désormais débiter son étude.

4 Analyse des données

4.1 Statistiques univariées

Une première observation simple de l'ensemble de données se fait simplement :

```
1 > summary(haberman)
2
3   age          year          nodes          status
4 Min.   :30.00   Min.   :58.00   Min.   : 0.000   Min.   :1.000
5 1st Qu.:44.00   1st Qu.:60.00   1st Qu.: 0.000   1st Qu.:1.000
6 Median :52.00   Median :63.00   Median : 1.000   Median :1.000
7 Mean   :52.46   Mean   :62.85   Mean   : 4.026   Mean   :1.265
8 3rd Qu.:60.75   3rd Qu.:65.75   3rd Qu.: 4.000   3rd Qu.:2.000
9 Max.   :83.00   Max.   :69.00   Max.   :52.000   Max.   :2.000
```

Quelques observations peuvent déjà être faites :

1. La médiane du nombre de noeuds lymphatiques positifs est de 1 et la moyenne de 4 (tout comme le troisième quartile). On en déduit qu'une très grande majorité des patients ont un nombre relativement faible de noeuds lymphatiques positifs, et qu'il existe une minorité de données aberrantes.
2. Le médiane de la survie des patients sur 5 ans est de 1, et la moyenne de 1.27. On en déduit une majorité de survivants dans le set de données avec environ 3 survivants pour un mort.

Afin de nous éclairer un peu plus quant aux répartitions des différentes variables, il est naturel de tracer leurs différents histogrammes :

```
1 barplot(table(haberman$variable),
2           main = "Distribution de la variable",
3           col = "lightblue",
4           xlab = "variable",
5           ylab = "Occurrences")
```

On obtient alors :




Figure 1: Histogrammes.

Nos précédentes conclusions sont ici mises en évidence. Puisque nous disposons désormais d'une vision plus précise des données avec lesquelles nous travaillons, plusieurs interrogations apparaissent naturellement :

- Y'a-t-il une relation entre l'âge et la survie du patient ?
- entre le nombre de noeuds lymphatiques positifs et la survie du patient ?
- entre l'année de la chirurgie et la survie du patient ?
- entre l'âge et le nombre de noeuds lymphatiques positifs du patient ?
- entre l'année de la chirurgie et le nombre de noeuds lymphatiques positifs

4.2 Statistiques bivariées


Toutes ces questions sont l'objet des statistiques bivariées. L'un des outils les plus efficaces pour caractériser de telles relations est la matrice de corrélation :

```
1 > cor(haberman)
2           age          year          nodes          status
3 age      1.00000000    0.089529446  -0.063176102  0.06795032
4 year      0.08952945    1.000000000  -0.003764474  -0.00476818
5 nodes    -0.06317610  -0.003764474    1.000000000  0.28676757
6 status    0.06795032  -0.004768180    0.286767567  1.00000000
```


Cependant, dans le cas présent, il n'existe aucune corrélation forte entre nos variables. Seul le nombre de noeuds lymphatiques positifs semble être positivement moyennement corrélé, avec une valeur de corrélation aux alentours de 0,3. Avoir plus de noeuds lymphatiques positifs indique donc une légère hausse de la mortalité sur les 5 ans suivant l'opération.

Afin de le visualiser concrètement, on peut s'intéresser à la moyenne du taux de mortalité dans les différents intervalles de noeuds lymphatiques positifs :

```
1 library(dplyr)
2 library(ggplot2)
3
4 #Graphe initiale
5 haberman %>%
6   group_by(nodes) %>%
7   summarise(mortalite = mean(status == 2)) %>%
8   ggplot(aes(x = nodes, y = mortalite, group = 1)) +
9   geom_line() +
10  geom_point()
11
12 #Graphe lisse
13 haberman %>%
14   mutate(noeuds_lymph = cut(
15     nodes,
16     breaks = c(-1, 0, 1, 2, 3, 4, 8, 15, 30, Inf),
17     labels = c("0", "1", "2", "3", "4", "5-8", "9-15", "16-30", "30+")
18   )) %>%
19   group_by(noeuds_lymph) %>%
20   summarise(mortalite = mean(status == 2)) %>%
21   ggplot(aes(x = noeuds_lymph, y = mortalite, group = 1)) +
22   geom_line() +
23   geom_point()
```



(a) Version lissée



(b) Version sans lissage

Figure 2: Survie en fonction du nombre de noeuds positifs.

4.3 Statistiques multivariées

4.3.1 ACP

Disposant d'un ensemble de variables quantitatives, un des outils les plus adaptés à leur étude est l'analyse en composantes principales.


On considère ici la survie ou non du patient sur 5 ans comme une variable qualitative. On projette donc un espace en 3 dimensions sur un plan en 2 dimensions, cette opération conserve donc logiquement une grande partie des données. On le confirme puisque la dimension 1 explique 37.05% de la variance et la dimension 2 en explique 33.22%, pour un total de 70.27%. On peut le vérifier grâce au diagramme en barres suivant :

```

1 eig <- res.pca$eig[,2]
2 bp <- barplot(eig,
3               names.arg = paste0("Dim ", 1:length(eig)),
4               col = "lightblue",
5               ylim = c(0, max(eig) + 10),
6               ylab = "% de variance expliquée",
7               main = "Diagramme en barre des valeurs propres")
8
9 text(bp,
10      eig + 2,
11      labels = round(eig,2))

```

Diagramme en barre des valeurs propres



L'analyse en composantes principales en elle-même donne le résultat suivant :

```
1 haberman$status <- as.factor(haberman$status)
2 levels(haberman$status) <- c("survie", "mort")
3 res.pca <- PCA(haberman, scale.unit=TRUE, quali.sup=4, graph=FALSE)
4 plot(res.pca,
5     choix="ind",
6     habillage = 4,
7     label="none")
```






Figure 4: Analyse de deux composantes principales

Puisque les ensembles de patients se chevauchent sur le graphe, il est assez complexe de conclure sur des indicateurs concrets de mortalité. On note tout de même que les survivants sont en général plus corrélés positivement sur Dim1 et négativement sur Dim2 et les morts négativement sur Dim1 et positivement sur Dim2 :



On peut désormais s'intéresser au cercle de corrélation afin de comprendre ce qui influence ces deux dimensions :

```
1 plot.PCA(res.pca, choix="var")
```



Si la dimension 2 semble être la plus indicatrice de la mortalité, on remarque que l'âge d'un patient lui est orthogonal, et donc sans influence. Seul le nombre de noeuds positifs et dans une moindre mesure, l'année d'opération, sont positivement corrélés à la dimension 2. Ainsi les valeurs positives sur la dimension 2 ont en général plus de noeuds positifs et qui ont été opéré plus tard que les patients aux coordonnées négatives sur cet axe. L'influence du nombre de noeuds positifs se retrouve ici comme dans notre analyse bivariée.

On peut d'ailleurs expliciter l'influence de chaque vecteur sur les dimensions :


```
1 > dimdesc(res.pca)
2 $Dim.1
3
4 Link between the variable and the continuous variables (R-square)
5 =====
6      correlation      p.value      n
7 age      0.7393405 3.730524e-54 306
8 year     0.6092222 1.786407e-32 306
9 nodes    -0.4399932 6.414256e-16 306
10
11 $Dim.2
12
13 Link between the variable and the continuous variables (R-square)
14 =====
15      correlation      p.value      n
16 nodes     0.8157693 2.884722e-74 306
17 year      0.5751882 2.387376e-28 306
18
19 ...
```

On peut désormais s'interroger sur l'existence de sous-groupes de patients similaires.

4.3.2 K-means

```
1 #Preparation des donnees
2 library(cluster)
3 scaledHaberman <- scale(haberman[1:3])
4 k_values <- 2:15
5 wss <- c()
6 sil <- c()
7 d <- dist(scaledHaberman)
8
9 #Recherche du nombre ideal de centres (silhouette)
10 for (k in k_values) {
11   km <- kmeans(scaledHaberman, centers = k, nstart = 20)
12   sil <- c(sil, mean(silhouette(km$cluster, d)[, 3]))
13 }
14 best_k <- k_values[which.max(sil)]
15
16 #K-means
17 final <- kmeans(scaledHaberman, centers = best_k, nstart = 20)
18
19 #affichage par ACP
20 res.pca <- PCA(scaledHaberman, graph = FALSE)
21 plot(res.pca$ind$coord, col = final$cluster, pch = 20)
```

On trouve que 4 est le meilleur nombre de sous-groupes par score de silhouette, avec un score de 0.32 donc relativement faible, et l'on affiche ensuite :



Les quatre sous-ensembles obtenus sont relativement diffus et se superposent, ce que l'on pouvait prévoir dans une certaine mesure avec la faiblesse du score de silhouette, et l'évidente absence de séparation claire de notre ensemble de données. L'application de cet algorithme a bien permis de séparer nos données en 4 ensembles relativement distincts, cependant ces derniers manquent toujours relativement de sens.

5 Commentaires

Nous avons procédé à l'étude du jeu de donnée de Haberman, sur 306 patients opérés pour cancer du sein entre 1958 et 1970.

En s'appuyant sur la structure du cours, nous avons pu évaluer l'ensemble de données selon différents critères à la précision et à la difficulté d'implémentation graduelles.

1. L'analyse univariée nous a permis de comprendre la nature des données que nous manipulons, leurs tendances, d'identifier les valeurs aberrantes et de dresser des hypothèses.
2. L'analyse bivariée nous a permis d'évaluer les relations entre les différentes variables, de réfuter une majorité de nos hypothèses et de confirmer l'existence, bien que faible, d'une corrélation positive entre le nombre de noeuds lymphatiques positifs et le taux de mortalité du patient.
3. L'analyse multivariée a tenté de trouver des relations entre plusieurs de nos données et de séparer nos populations en groupes distincts caractéristiques. Cependant, le nombre réduit de variables étudiées, sur un nombre de patients lui aussi réduit, nous a malheureusement empêché d'obtenir de nouveaux résultats. Nous avons cependant encore une fois réussi à valider nos résultats d'analyse bivariée à l'aide de nouvelles méthodes.

Afin d'obtenir des résultats plus concluants, augmenter la taille de l'échantillon et ajouter de nouvelles variables directement liées, telles que la présence de comorbidités, de récurrence, etc. semble être une piste. En effet la contrainte majeure ici est le manque d'informations utiles quant à la condition médicale examinée, puisque sur les 3 variables examinées, seul le nombre de noeuds lymphatiques positifs a démontré une véritable pertinence.